Ana Rivera Morales, *EcMe*

Base de Datos

Este documento acompaña al trabajo *"Predicción de la eficiencia energética de edificios residenciales: Comparación de MCO, Lasso, Random Forest, Redes Neuronales y Eco-Retina"* y describe la base de datos empleada en el análisis. El objetivo es recoger de forma clara el origen de los datos, las variables utilizadas y el tratamiento previo aplicado antes de estimar los modelos.

La base de datos utilizada procede de Tsanas y Xifara (2012) y contiene 768 observaciones correspondientes a edificios residenciales simulados mediante *Ecotect*. La variable dependiente es *heating_load*, medida en kWh/m². Antes de la estimación, se renombran las variables originales para facilitar su interpretación, se verifica la ausencia de valores perdidos y se adaptan los separadores decimales y de columnas para garantizar la correcta lectura. Finalmente, se realiza una partición aleatoria común para todos los modelos: 75% para entrenamiento, N = 576, y 25% para test, N = 192.

Las variables explicativas continuas se mantienen en nivel, al representar magnitudes físicas con orden natural:

- **relative_compactness**: compacidad relativa del edificio.
- **surface_area**: superficie total del edificio, en m².
- **wall_area**: área de paredes, en m².
- **roof_area**: área de cubierta, en m².
- ***overall_height*:** altura total del edificio, en metros.
- ***glazing_area_modified***: proporción de superficie acristalada, modificada; construida como glazing_area_modified = glazing_area + 1, para evitar valores nulos en inversas o divisiones

Las variables categóricas son ***orientation*** y ***glazing_area_distribution***. La primera recoge la orientación del edificio y toma cuatro valores posibles, asociados a las cuatro orientaciones cardinales. La segunda recoge la distribución del acristalamiento: uniforme, concentración en el norte, este, sur u oeste, y ausencia de acristalamiento. Ambas variables se codifican mediante *dummies*: ***orientation_2*** a ***orientation_5*** y ***glazing_dist_1*** a ***glazing_dist_6***. En las estimaciones se omite una categoría de referencia por cada variable categórica para evitar multicolinealidad perfecta: *orientation_2* y *glazing_dist_1*. Por tanto, los coeficientes de las *dummies* se interpretan respecto a estas categorías.

La Tabla 1 recoge los estadísticos descriptivos principales. Destacan dos características estructurales del *dataset*: *overall_height* solo toma dos valores (3.5 m y 7.0 m), lo que genera dos regímenes de comportamiento bien diferenciados, y las variables de forma (compacidad, superficie y área de cubierta) presentan correlaciones muy elevadas entre sí por la restricción de volumen constante. Ambas características tienen consecuencias directas sobre los modelos estimados, como se discute en la sección de resultados, en el documento principal de este trabajo.

Variable	N	Mín.	Máx.	Media	D.T.
relative_compactness	12	0.62	0.98	0.764	0.105
surface_area (m²)	12	514.5	808.5	671.7	88.1
wall_area (m²)	7	245.0	416.5	318.5	43.6
roof_area (m²)	4	110.25	220.5	176.6	45.2

overall_height (m)	2	3.5	7.0	5.25	1.75
glazing_area_mod.	4	1.0	1.4	1.235	0.133
orientation	4	2	5	—	—
glazing_dist.	6	0	5	—	—
heating_load (kWh/m²)	**586**	**6.01**	**43.10**	**22.31**	**10.09**

Tabla 1. Estadísticos descriptivos de las variables (Fte. Elaboración propia)

Nota. Todos los materiales asociados al trabajo se encuentran disponibles en el repositorio de GitHub: https://github.com/anariver02/Trabajo_Final_Econometria
El repositorio incluye el trabajo principal, este documento descriptivo, el resumen en inglés, la base de datos original, las particiones de entrenamiento y test, los códigos utilizados para cada algoritmo en Google Colab y el artículo de referencia de Tsanas y Xifara (2012). De este modo, se facilita la consulta del material y la reproducibilidad del análisis.