Ana Rivera Morales, *EcMe*

Predicción de la eficiencia energética de edificios residenciales
Comparación de MCO, Lasso, Random Forest, Redes Neuronales y Eco-RETINA

Resumen

Este trabajo compara cinco modelos de predicción de la carga de calefacción (*heating load*) en edificios residenciales: Mínimos Cuadrados Ordinarios, Lasso, Eco-Retina, Random Forest y redes neuronales. La base de datos utilizada procede de simulaciones energéticas de 768 edificios, descritos mediante variables geométricas y de acristalamiento. El interés econométrico del problema reside en que varias variables de forma están fuertemente correlacionadas por construcción, al mantenerse constante el volumen de los edificios. Por ello, el ejercicio permite comparar modelos lineales, regularizados y no lineales en un contexto con multicolinealidad estructural e interacciones entre regresores. Los resultados muestran que los modelos no lineales mejoran sustancialmente la predicción fuera de muestra. La Red Neuronal obtiene el menor error predictivo, seguida de Random Forest, mientras que Eco-Retina ofrece un equilibrio atractivo entre flexibilidad e interpretabilidad. En conjunto, el trabajo confirma que la demanda de calefacción depende de relaciones no lineales entre forma, altura y acristalamiento.

1. Introducción

En el contexto de la Agenda 2030 y de las políticas de eficiencia energética, la predicción de la demanda energética de los edificios residenciales constituye un problema relevante tanto para el diseño arquitectónico como para la evaluación de medidas de sostenibilidad. En particular, la carga de calefacción (*heating load*) aproxima la energía necesaria para mantener unas condiciones interiores de confort, por lo que su estimación permite comparar diseños y anticipar necesidades energéticas. Los edificios en la Unión Europea están legalmente obligados a cumplir requisitos mínimos de eficiencia energética, y la calidad de los modelos predictivos que sustentan los certificados de calificación determina directamente la utilidad de ese instrumento de política.

Este trabajo utiliza la base de datos de Tsanas y Xifara (2012), formada por 768 edificios residenciales simulados mediante *Ecotect*. En particular, la descripción detallada de la base de datos utilizada en este trabajo, y del tratamiento de variables realizado, se recoge en un documento complementario adjunto en formato PDF. El interés de esta base de datos no reside únicamente en la aplicación energética, sino también en su estructura econométrica: todos los edificios tienen el mismo volumen, de modo que varias variables geométricas están relacionadas entre sí por construcción. Esta multicolinealidad no es un artefacto estadístico, sino una consecuencia física del diseño experimental, y convierte el conjunto de datos en un banco de pruebas exigente para los modelos lineales. El problema aparece también en datos reales: Raushan et al. (2024) documentan que el 30% de los registros de la base de certificados energéticos de Irlanda contienen errores, concentrados mayoritariamente en variables geométricas.

El objetivo del trabajo es comparar cinco enfoques de modelización con distinto grado de flexibilidad: MCO, Lasso, Eco-Retina, Random Forest y redes neuronales. La comparación se realiza sobre una partición entrenamiento/test fija (75%/25%) y atiende a métricas de predicción fuera de muestra como R^2, RMSE, MAE y MAPE. Si bien el propósito no es solo identificar el modelo con menor error, sino valorar el equilibrio entre precisión predictiva, estabilidad e interpretabilidad econométrica.

Así, el trabajo se organiza en cuatro secciones. Tras esta introducción, la sección 2 presenta los resultados para cada modelo. La sección 3 compara los enfoques estimados, identificando el modelo más adecuado según el equilibrio entre precisión predictiva e interpretabilidad. Finalmente, la sección 4 expone las conclusiones principales de este trabajo, sus limitaciones y posibles futuras líneas de investigación.

2. Resultados de cada modelo

Esta sección presenta los resultados de los cinco algoritmos comparados: MCO, Eco-Retina, Lasso, Random Forest y Redes Neuronales. Todos se estiman sobre la misma muestra de entrenamiento (N=576) y se evalúan sobre el conjunto de prueba (N=192), garantizando la comparabilidad de los resultados.

2.1 Modelo Lineal General (MCO)

El Modelo Lineal General estimado por Mínimos Cuadrados Ordinarios (MCO) constituye el modelo de referencia del trabajo. Las variables entran sin transformaciones, y se estima con errores HC3 para corregir la heteroscedasticidad (*test de Breusch-Pagan*: estadístico LM=271.66, p<0.001), esperable dado que el dataset combina variables en escalas muy distintas (*surface_area* en cientos de m² frente a *relative_compactness* entre 0 y 1). Se omite una categoría en cada variable categórica: *orientation_2* y *glazing_dist_1* para evitar la "trampa de la multicolinealidad". Así, el modelo estimado tiene 14 regresores más la constante:

$$\begin{aligned}\widehat{heating_load}_i = {} & 66.491_{(5.493)} - 66.831_{(-10.117)} \cdot relative_compactness_i - 0.063_{(-7.322)} \cdot surface_area_i \\ & + 0.035_{(7.579)} \cdot wall_area_i - 0.049_{(-8.682)} \cdot roof_area_i + 4.268_{(10.656)} \cdot overall_height_i \\ & + 16.739_{(17.779)} \cdot glazing_area_\text{modified}_i + 0.047_{(0.149)} \cdot orientation_3_i \\ & + 0.001_{(0.004)} \cdot orientation_4_i + 0.045_{(0.138)} \cdot orientation_5_i + 4.240_{(5.855)} \cdot glazing_dist_2_i \\ & + 4.242_{(5.897)} \cdot glazing_dist_3_i + 4.084_{(5.535)} \cdot glazing_dist_4_i + 4.094_{(5.709)} \cdot glazing_dist_5_i \\ & + 4.133_{(5.665)} \cdot glazing_dist_6_i\end{aligned}$$

Ecuación estimada 1 — MCO (t-estadísticos HC3 entre paréntesis)

Todas las variables continuas son significativas al 0.1% (p<0.001). El mayor impacto corresponde a *glazing_area_modified* (coef=16.739), revelando que el nivel de acristalamiento es el principal determinante de la carga de calefacción. Las *dummies* de distribución del acristalamiento (*glazing_dist_2* a *glazing_dist_6*) son también significativas, con coeficientes entre 4.08 y 4.24 kWh/m² respecto a la categoría de referencia (distribución uniforme). Las *dummies* de orientación (*orientation_3, 4 y 5*) no son significativas (p>0.88), resultado coherente con Tsanas y Xifara (2012).

Bondad de ajuste y Métricas de predicción

El R^2=0.928 (ajustado=0.927) y F(13,562)=1076 (p≈0) confirman la capacidad explicativa y significatividad global del modelo. Sin embargo, presenta dos limitaciones estructurales:

1. Los residuos rechazan la normalidad (Jarque-Bera=25.02, p<0.001), consecuencia estructural del diseño del *dataset*: *overall_height* solo toma dos valores (3.5m y 7.0m), generando dos nubes de observaciones con comportamiento diferenciado. Además, transformaciones logarítmicas de la variable dependiente no mejoraron la normalidad ni el ajuste predictivo.
2. El modelo presenta multicolinealidad severa por construcción: como todos los edificios tienen el mismo volumen, *relative_compactness* y *surface_area* están ligadas por una relación analítica (r=−0.992), con VIF divergente. Esta multicolinealidad no invalida las predicciones del modelo, pero sí hace que los coeficientes individuales de ambas variables sean inestables y no puedan interpretarse de forma aislada.

La Tabla 1 recoge las métricas de predicción fuera de muestra. La caída del R^2 de 0.928 (*train*) a 0.911 (test) es moderada e indica buena capacidad de generalización. A diferencia de RF y RN, el MCO genera intervalos de predicción individuales; sin embargo, dado que su construcción asume normalidad de los residuos, supuesto rechazado en este *dataset*, la cobertura empírica es del 85.9%, inferior al 95% nominal.

Métrica	Train (N=576)	Test (N=192)
R^2	0.928	0.911

RMSE (kWh/m²)	—	3.025
MAE (kWh/m²)	—	2.184
MAPE (%)	—	10.23%

Tabla 1. Métricas MLG(MCO) en datasets train y test (Fte. Elaboración propia)

La Figura 1 revela gráficamente que el modelo tiende a sobrepredecir valores bajos (5–15 kWh/m²) e infrapredecir altos (>30 kWh/m²), comprimiendo las predicciones hacia la media, patrón característico de modelos lineales aplicados a relaciones no lineales.

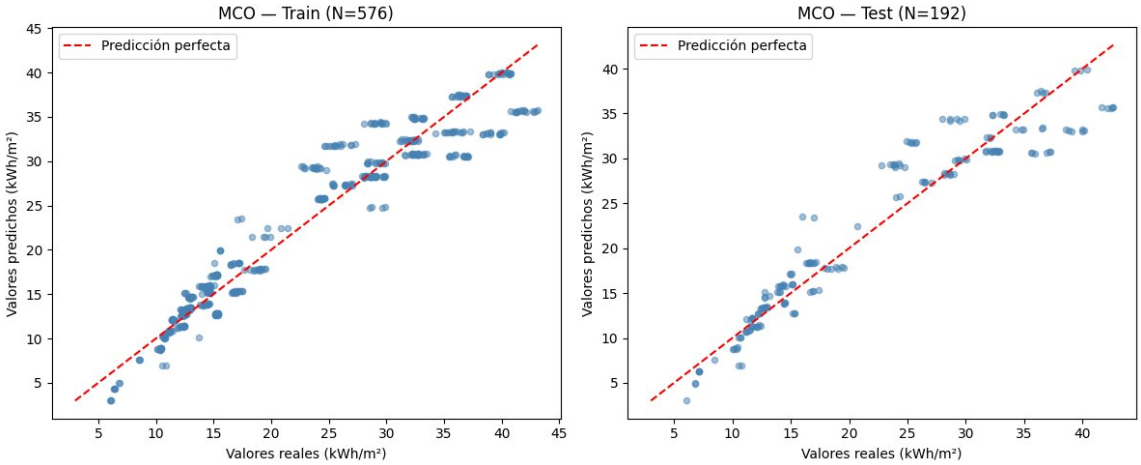

Figura 1. Valores predichos vs. valores reales (train y test) – MLG (MCO)
La línea roja discontinua representa la predicción perfecta (predicho = real)

2.2 Lasso

Lasso (*Least Absolute Shrinkage and Selection Operator*) extiende el MCO añadiendo una penalización sobre la suma de valores absolutos de los coeficientes, controlada por el hiperparámetro λ, seleccionado mediante validación cruzada de 10 pliegues (λ=0.009). Esta penalización fuerza que algunos coeficientes sean exactamente cero, realizando selección automática de variables. Con esta configuración, Lasso elimina *wall_area* y *orientation_4*, reteniendo 12 regresores.

Sus métricas fuera de muestra (Tabla 2) son prácticamente idénticas al MCO (RMSE_test=3.032 vs 3.025), lo que indica que la regularización no aporta capacidad predictiva adicional en este *dataset*. La causa es que la multicolinealidad estructural no se resuelve penalizando coeficientes, sino capturando las interacciones entre variables, como hace Eco-Retina en el modelo siguiente. A diferencia del MCO y Eco-RETINA, Lasso no genera intervalos de predicción individuales.

Métrica	Train (N=576)	Test (N=192)
R²	0.928	0.911
RMSE (kWh/m²)	—	3.032
MAE (kWh/m²)	—	2.198
MAPE (%)	—	10.31%

Tabla 2. Métricas Lasso en datasets train y test (Fte. Elaboración propia)

La Figura 2 muestra el patrón de compresión hacia la media idéntico al del MCO, confirmando que Lasso no resuelve la no linealidad subyacente del problema.

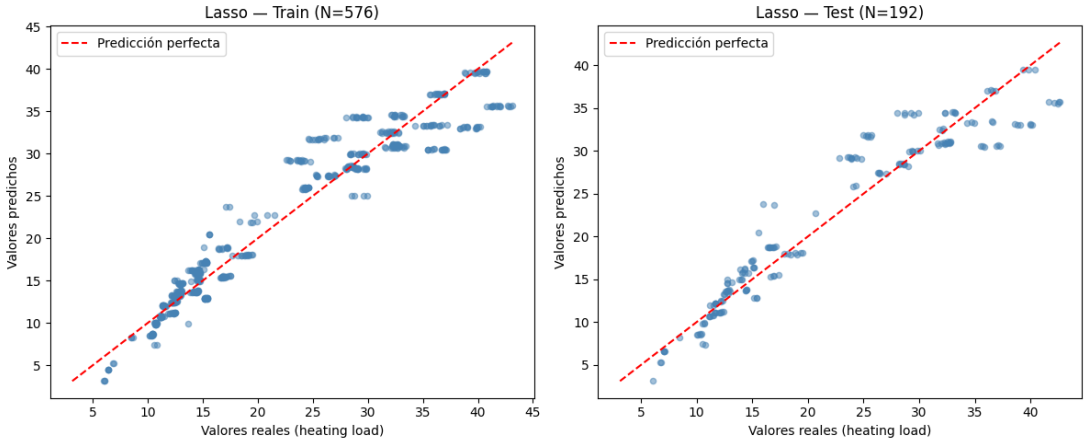

Figura 2. Valores predichos vs. valores reales (train y test) – Lasso
La línea roja discontinua representa la predicción perfecta (predicho = real)

2.3 Eco-Retina

Eco-RETINA (Capilla et al., 2025) es un algoritmo de modelización automática de modelos de predicción, lineal en los parámetros pero no lineal en los *inputs* originales. Genera candidatos de regresores mediante transformaciones de los *inputs* (potencias, inversas y productos cruzados, controlados por el hiperparámetro *Params*) y los incorpora secuencialmente, añadiendo en cada iteración el regresor que más reduce la función de pérdida evaluada en el conjunto de *test*, no en el de entrenamiento. El proceso se detiene cuando ninguna transformación adicional reduce el error fuera de muestra, garantizando modelos libres del sesgo de selección descrito por Miller (1984). Al estimarse por MCO (en este caso, con errores HC3), preserva la interpretabilidad econométrica: coeficientes, estadísticos z e intervalos de predicción.

Hiperparámetros y selección del modelo

Con el objetivo de identificar la especificación más adecuada para el problema, se experimentó con cinco configuraciones alternativas de hiperparámetros. Las dos dimensiones que varían entre configuraciones son: *Params*, que determina qué exponentes pueden aplicarse a los inputs continuos (el valor [-1.0, 0.0, 1.0] permite inversas, términos en nivel y valores originales, mientras que añadir 2.0 incorpora también términos cuadráticos), y *Cross dummy*, que controla la posibilidad de incluir productos cruzados con las variables *dummy*. El resto de hiperparámetros se mantuvieron fijos en todos los experimentos: función de pérdida MSE, estimación OLS, covarianza HC3, Max R^2=0.99 y semilla=8. La Tabla 3 recoge los resultados:

Config.	Cross dummy	Params	R^2_train	R^2_test	RMSE_test	MAE_test	#Regresores
1	**False**	**[-1.0, 0.0, 1.0]**	**0.933**	**0.923**	**2.820**	**2.088**	**14**
2	True	[-1.0, 0.0, 1.0]	0.918	0.896	3.272	2.465	3
3	False	[-1.0, 0.0, 1.0, 2.0]	0.929	0.906	3.101	2.152	2
4	True	[-1.0, 0.0, 1.0, 2.0]	0.934	0.915	2.956	2.130	7

Tabla 3. Sensibilidad a hiperparámetros — Eco-RETINA (Fte. Elaboración propia)

El modelo seleccionado (#1) tiene 14 regresores, todos productos cruzados entre variables, estimado sobre N=576 con HC3. El estadístico F(14,561)=1486 (p≈0) confirma la significatividad conjunta; R^2=0.933, R^2ajustado=0.931.

$$\begin{aligned}\widehat{heating_load}_i = & -297.26_{(-10.479)} + 3.216_{(39.604)} \cdot overall_height_i \cdot glazing_area_modified_i - 2659.16_{(-15.021)} \\ & \cdot wall_area^{-1}{}_i \cdot glazing_area_modified_i + 3.549_{(4.886)} \cdot glazing_dist_6_i \cdot relative_compactness_i \\ & + 0.0089_{(4.886)} \cdot glazing_dist_3_i \cdot wall_area_i + 0.0090_{(5.274)} \cdot glazing_dist_2_i \cdot wall_area_i \\ & + 0.571_{(10.024)} \cdot relative_compactness_i \cdot surface_area_i \\ & + 0.031_{(17.851)} \cdot wall_area_i \cdot glazing_area_modified_i \\ & + 0.489_{(4.503)} \cdot glazing_dist_5_i \cdot overall_height_i + 0.0076_{(4.094)} \cdot roof_area_i \cdot overall_height_i \\ & + 0.404_{(3.236)} \cdot glazing_dist_4_i \cdot overall_height_i + 0.0003_{(0.312)} \cdot orientation_3_i \cdot wall_area_i \\ & + 0.054_{(0.594)} \cdot orientation_5_i \cdot overall_height_i + 0.0041_{(1.811)} \cdot glazing_dist_4_i \cdot roof_area_i \\ & - 0.0006_{(-0.289)} \cdot orientation_5_i \cdot roof_area_i\end{aligned}$$

Ecuación estimada 2 — Eco-Retina (t-estadísticos HC3 entre paréntesis)

Once de los catorce términos son significativos al 0.1%. El término de mayor impacto es *overall_height* × *glazing_area_modified* (z=39.60): a mayor altura, el efecto del acristalamiento sobre la carga de calefacción se amplifica, interacción que el MCO no puede capturar. El producto *relative_compactness* × *surface_area* (z=10.02) resuelve endógenamente la multicolinealidad severa del MCO: al combinar ambas variables en un único término, Eco-Retina obtiene un coeficiente estable donde el MCO producía estimaciones no fiables. Los tres términos no significativos implican en todos los casos variables de orientación, confirmando su irrelevancia predictiva.

Métricas de ajuste y predicción

La Tabla 4 recoge las métricas de ajuste y predicción del modelo seleccionado. El R^2 desciende apenas 1.1 puntos porcentuales entre el conjunto de entrenamiento (0.933) y el de *test* (0.923), lo cual indica una capacidad de generalización sólida especialmente relevante dada la especificación no lineal del modelo.

Métrica	Train (N=576)	Test (N=192)
R^2	0.933	0.923
RMSE (kWh/m²)	—	2.820
MAE (kWh/m²)	—	2.088
MAPE (%)	—	10.14%

Tabla 4. Métricas Eco-RETINA en datasets train y test (Fte. Elaboración propia)

La Figura 3 muestra las predicciones frente a los valores reales: ambas líneas siguen el mismo patrón con desviaciones puntuales en los picos.

La Figura 4 recoge dos tipos de intervalos al 95%. El gráfico de la izquierda muestra los intervalos de confianza (banda estrecha), que cuantifican la incertidumbre sobre el valor medio esperado. El de la derecha muestra los intervalos de predicción (banda más amplia), relevantes para predecir un edificio concreto. La cobertura empírica de estos últimos es inferior al 95% nominal por la no normalidad estructural de los residuos, limitación compartida con el MCO.

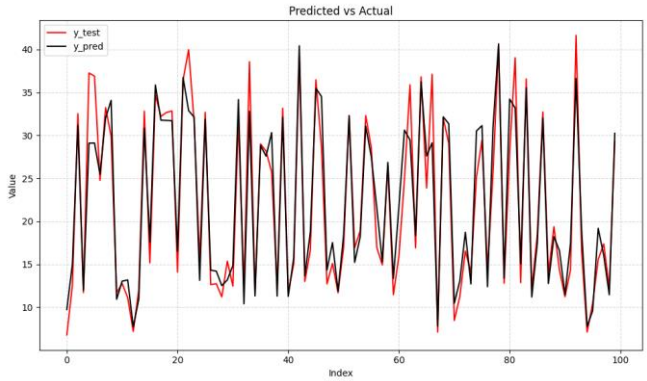

Figura 3. Valores predichos vs. valores reales (test) — Eco-RETINA
Las líneas roja (real) y negra (predicha) siguen el mismo patrón con alta precisión.

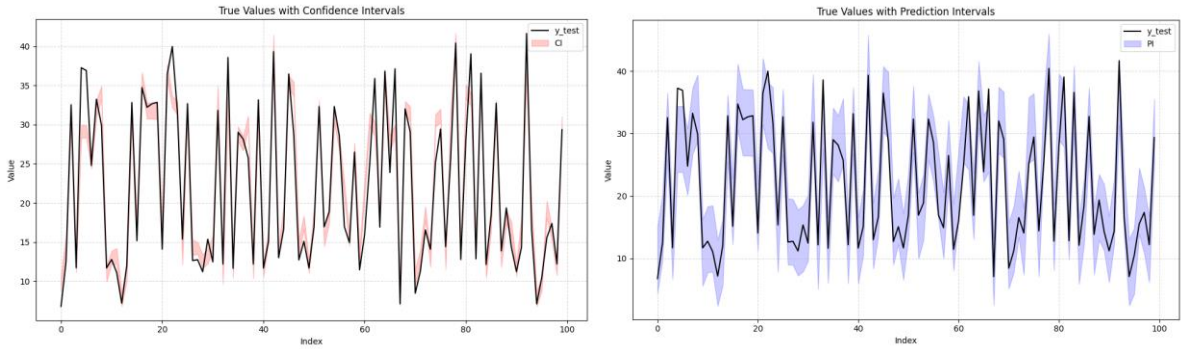

Figura 4. Eco-RETINA: Intervalos al 95% sobre el conjunto de test (N=192). Línea negra: valores reales.
Izquierda: intervalos de confianza (banda rosa) sobre el valor medio esperado.
Derecha: intervalos de predicción (banda azul) sobre observaciones individuales.

2.4 Random Forest

Random Forest es un método de aprendizaje en conjunto que construye múltiples árboles de decisión, cada uno entrenado sobre una submuestra aleatoria con reemplazamiento y evaluando en cada nodo solo un subconjunto aleatorio de variables. Esta doble aleatoriedad reduce la correlación entre árboles, produciendo modelos más estables y precisos que un árbol individual.
A diferencia de los modelos lineales, RF captura relaciones no lineales e interacciones entre variables sin necesidad de especificación previa, no requiere supuestos sobre distribuciones y es inmune a la multicolinealidad por diseño: al evaluar en cada nodo solo un subconjunto de variables, el algoritmo prescinde de forma natural de predictores redundantes. Su principal limitación frente al MCO y a Eco-Retina es la pérdida de interpretabilidad, ya que no produce coeficientes individuales ni intervalos de predicción formales.

Hiperparámetros y selección del modelo

Se experimentó con cuatro hiperparámetros principales. Número de árboles (n_estimators): el rendimiento se estabiliza a partir de n=200 (RMSE_test=1.180), con mejoras marginales al aumentar hasta n=500 (RMSE_test=1.175). Se adopta n=500 como margen de seguridad frente a la variabilidad de muestreo, sin coste computacional relevante; max_depth: sin límite de profundidad, ya que restringirla deteriora la predicción (RMSE_test=3.194 con max_depth=3); min_samples_leaf=1 es óptimo; max_features: se adopta sqrt(p) para preservar la aleatoriedad en la selección de variables, mecanismo central de RF para reducir la correlación entre árboles; valores mayores (1.0) mejoran el RMSE pero eliminan esa aleatoriedad.

Métricas de ajuste y predicción

Métrica	Train (N=576)	Test (N=192)
R²	0.9982	0.9866
RMSE (kWh/m²)	0.4273	1.1750
MAE (kWh/m²)	0.3092	0.8228
MAPE (%)	—	4.99%

Tabla 5. Métricas Random Forest en datasets train y test (Fte. Elaboración propia)

El R² desciende de 0.9982 en *train* a 0.9866 en *test*, una caída de 1.2 puntos porcentuales. Un modelo sobreajustado mostraría una caída mucho más pronunciada al pasar a datos no vistos; la moderada diferencia observada indica que el modelo generaliza bien pese a su flexibilidad. El MAPE es 4.99%, indicando que el error medio de predicción no supera el 5% del valor real.

La Figura 5 muestra que en entrenamiento el ajuste es prácticamente perfecto, mientras que en test aparece algo más de dispersión en el rango alto de carga (>30 kWh/m²), sin que ello genere un patrón sistemático de infra o sobrepredicción.

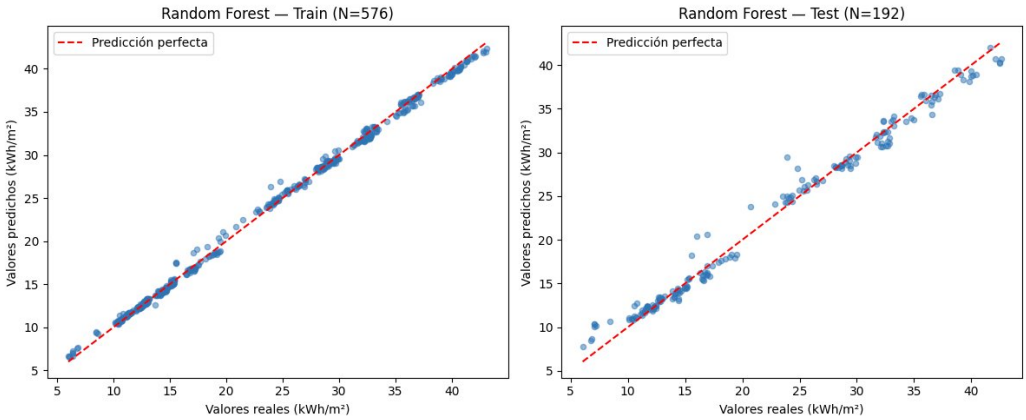

Figura 5. Random Forest: Valores predichos vs. reales (train y test)

Importancia de variables

La Figura 6 recoge la importancia de cada variable por permutación: cuánto empeora el R²_test al aleatorizar esa variable manteniendo el resto fijas. La variable *glazing_area_modified* es la más determinante (caída de 0.131 puntos), mientras que las variables de orientación muestran de nuevo importancia prácticamente nula.

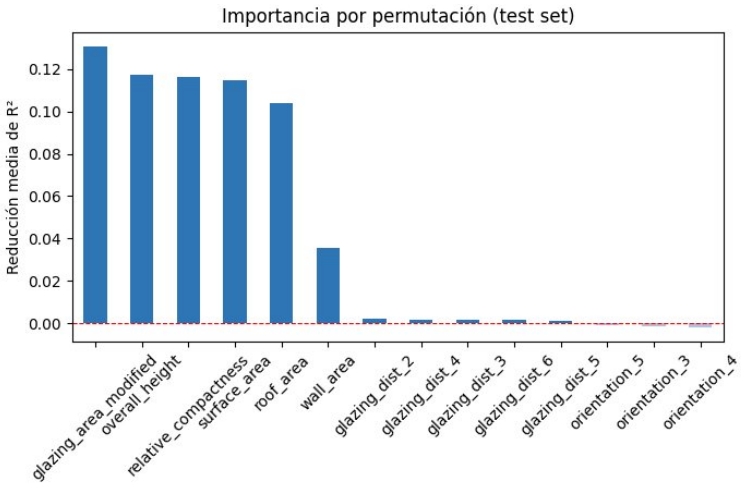

Figura 6. Random Forest: Importancia por permutación (Fte. Elaboración propia)

2.5 Red Neuronal

Las redes neuronales artificiales son modelos de predicción organizados en capas: una capa de entrada, una o varias capas ocultas y una capa de salida. Cada neurona aplica una transformación no lineal a una combinación ponderada de las salidas de la capa anterior, y el ajuste consiste en optimizar esos pesos mediante descenso por gradiente. La función de activación ReLU (max(0, x)) introduce no linealidad manteniendo gradientes estables durante el entrenamiento. Su capacidad para aproximar relaciones complejas entre variables las convierte en una alternativa natural en problemas con no linealidades e interacciones que los modelos lineales no capturan.

Hiperparámetros y selección del modelo

Las configuraciones iniciales con early stopping producían convergencia inestable entre semillas (rangos de RMSE de 2.47-3.41 puntos) por el reducido subconjunto de validación interna (52 observaciones). La arquitectura definitiva, relu (64,32), elimina la parada temprana (max_iter=5000, tol=1e-5) y logra estabilidad: el RMSE_test oscila entre 0.566 y 1.083 kWh/m² sobre siete semillas, con seis de las siete por debajo de 1.0 y diferencia máxima R^2_train - R^2_test de 0.011. Las métricas reportadas corresponden a la media de las siete semillas (Figura 7).

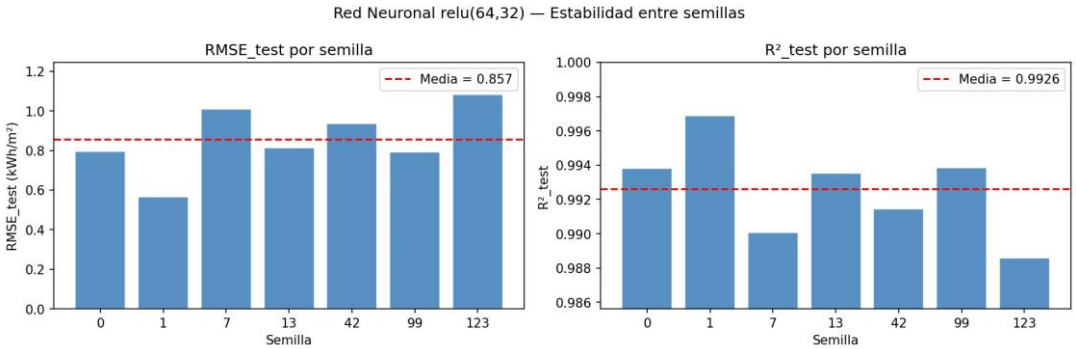

Figura 7. Red Neuronal relu(64,32): RMSE_test y R^2_test por semilla.
La línea roja discontinua indica la media de las 7 semillas. (Fte. Elaboración propia)

Métricas de ajuste y predicción

La Tabla 8 recoge las métricas del modelo. El R^2_test medio es 0.993 y el RMSE_test medio es 0.857 kWh/m², el valor más bajo de todos los modelos del trabajo. La diferencia media entre R^2_train (0.9995) y R^2_test (0.9926) es de 0.007 puntos, confirmando una generalización sólida pese a la alta flexibilidad del modelo.

Métrica	Train (N=576)	Test (N=192)
R^2	0.9995	0.9926*
RMSE (kWh/m²)	—	0.857*
MAE (kWh/m²)	—	0.588*
MAPE (%)	—	3.50%*

*Tabla 8. Métricas Red Neuronal relu (64,32) en datasets train y test. *Media de 7 semillas. (Fte. Elaboración propia)*

La Figura 8 representa los valores predichos frente a los reales sobre la semilla más representativa (13). Los puntos se agrupan muy cerca de la línea de predicción perfecta en ambos conjuntos, sin el patrón de compresión hacia la media observable en MCO y Lasso.

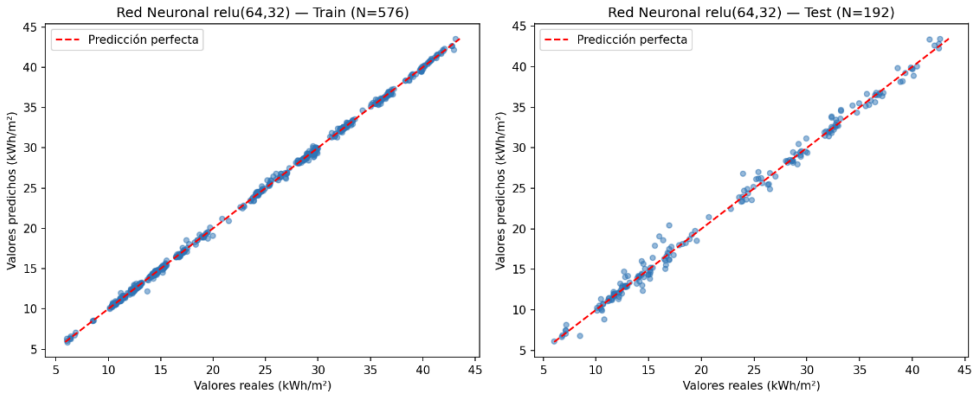

Figura 8. Red Neuronal relu(64,32): RMSE_test y R²_test por semilla.
La línea roja discontinua indica la media de las 7 semillas. (Fte. Elaboración propia)

3. Comparación entre modelos

La Tabla 9 recoge las métricas de predicción de los cinco modelos sobre el conjunto de *test* y resume sus ventajas e inconvenientes principales.

Modelo	R²_test	RMSE_test	MAE_test	MAPE_test	Ventaja ppal.	Limitación ppal.
MCO	0.911	3.025	2.184	10.23%	Interpretabilidad y referencia lineal	Multicolinealidad; no linealidad no capturada
Eco-Retina	0.923	2.820	2.088	10.14%	Interacciones interpretables	Mejora moderada sobre MCO
Lasso	0.911	3.026	2.198	10.31%	Selección automática de variables	No IC individuales; multicolinealidad no resuelta
Random Forest	0.987	1.175	0.823	4.99%	Alta precisión, robusto a multicolinealidad	Menor interpretabilidad
Red Neuronal	0.993*	0.857*	0.588*	3.50%*	Mejor precisión global en predicciones	Requiere test de robustez. Menor transparencia estructural

Tabla 9. Resumen comparativo de los cinco modelos sobre el conjunto de test (N=192). *Media de 7 semillas. (Fte. Elaboración propia)

MCO y Lasso obtienen métricas prácticamente idénticas (R^2_test = 0.911, RMSE_test ≈ 3.03 kWh/m²), lo que confirma que la regularización no aporta ventaja predictiva cuando la multicolinealidad tiene origen físico: Lasso puede seleccionar variables, pero no puede resolver una dependencia impuesta por la restricción de volumen constante. Ambos modelos presentan además un patrón sistemático de compresión hacia la media, sobreestimando las cargas bajas e infraestimando las altas, señal de que la relación entre variables no es puramente aditiva.

Eco-Retina mejora moderadamente sobre los lineales (R^2_test = 0.923, RMSE_test = 2.820 kWh/m²). Su aportación principal no es solo predictiva sino interpretativa: los regresores seleccionados son productos cruzados entre variables, lo que confirma que la carga de calefacción responde a efectos conjuntos entre altura, acristalamiento y

variables de forma. Al combinar *relative_compactness* × *surface_area* en un único término, resuelve endógenamente la multicolinealidad que lastra al MCO, manteniendo coeficientes, p-valores e intervalos de predicción formales.

Random Forest (R^2_test = 0.987, RMSE_test = 1.175 kWh/m²) y la Red Neuronal (R^2_test = 0.993, RMSE_test = 0.857 kWh/m²) superan con claridad a los modelos lineales. Ambos capturan no linealidades e interacciones sin especificación previa y son inmunes a la multicolinealidad por diseño. La importancia por permutación del RF sitúa glazing_area_modified como predictor dominante, mientras que la orientación resulta irrelevante en todos los modelos. La Red Neuronal es el modelo ganador en términos predictivos, con una diferencia media R^2_train - R^2_test de 0.007 sobre siete semillas que descarta sobreajuste. Su principal limitación frente a Eco-RETINA es la ausencia de coeficientes interpretables e intervalos de predicción individuales.

En conjunto, los resultados muestran que la relación entre las características físicas del edificio y la carga de calefacción no es puramente lineal ni aditiva. Las variables geométricas son relevantes, pero su efecto depende de cómo interactúan con otras características, especialmente con el acristalamiento. Esta conclusión explica por qué los modelos más flexibles que incorporan técnicas de ML, como Random Forest y Red Neuronal, superan a los modelos lineales en predicción fuera de muestra.

4. Conclusiones

La conclusión principal es, por tanto, que la elección del modelo más adecuado depende del objetivo del análisis. Si se prioriza la precisión predictiva, la red neuronal es la mejor alternativa. Si se busca un modelo muy preciso, pero algo más interpretable mediante importancia de variables, Random Forest ofrece un equilibrio sólido. Si el objetivo es mantener una lectura econométrica explícita de los regresores, Eco-Retina resulta preferible, ya que introduce interacciones y transformaciones sin renunciar por completo a la interpretación de coeficientes. Finalmente, MCO y Lasso son útiles como modelos de referencia, pero resultan insuficientes para capturar por completo la estructura no lineal del problema.

Como limitación, debe señalarse que los datos proceden de simulaciones energéticas y no de consumos observados reales. Por ello, los resultados deben interpretarse como predicción de la carga de calefacción simulada bajo condiciones controladas. Futuras extensiones podrían incorporar la carga de refrigeración, comparar la estabilidad de los modelos mediante validación cruzada repetida o aplicar la metodología a bases de datos reales de certificados energéticos. Aun así, el ejercicio confirma que los métodos de aprendizaje automático pueden aportar mejoras sustanciales en la predicción energética de edificios, especialmente cuando existen multicolinealidad estructural e interacciones entre variables de diseño.

Bibliografía

- Breiman, L. (2001). *Random forests. Machine Learning*, 45, 5–32
- Capilla, J., Alcaraz, A., Valarezo, Á., García-Hiernaux, A., & Pérez-Amaral, T. (2025). *Eco-RETINA: A green flexible algorithm for model building*. Universidad Complutense de Madrid.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer.
- Raushan, K., Mac Uidhir, T., Llorens Salvador, M., Norton, B., & Ahern, C. (2024). *A data-driven standardised generalisable methodology to validate a large energy performance certification dataset: A case of the application in Ireland. Energy and Buildings*, 323, 114774.
- Tsanas, A., & Xifara, A. (2012). *Accurate quantitative estimation of energy performance of residential buildings using statistical machine learning tools. Energy and Buildings*, 49, 560–567.
- OpenAI (2025). ChatGPT (vs GPT-4/5). *Nota: Utilizado para asistir en la consulta y análisis de información.*

Nota: Todos los materiales utilizados para la elaboración de este trabajo se encuentran disponibles en el siguiente repositorio de GitHub: https://github.com/anariver02/Trabajo_Final_Econometria De este modo, se facilita la reproducibilidad del análisis y la consulta de los resultados obtenidos.